

EKG İşaretinin Makine Öğrenme Yöntemleri ile Sınıflandırılması

Classification of ECG Signal by using Machine Learning Methods

Aykut DİKER
Enformatik Bölümü,
Bitlis Eren
Üniversitesi,
Bitlis, Türkiye
adiker@beu.edu.tr

Engin AVCI
Yazılım
Mühendisliği
Fırat Üniversitesi,
Elazığ, Türkiye
enginavci23@gmail.com

Zafer CÖMERT
Bilgisayar
Mühendisliği, Bitlis
Eren Üniversitesi,
Bitlis, Türkiye
cömertzafer@gmail.com

Derya AVCI
Teknik Bilimler
MYO
Fırat Üniversitesi,
Elazığ, Türkiye
davci@firat.edu.tr

Emine KAÇAR,
İhsan
SERHATLIOĞLU,
Temel Tıp Bilimleri
Bölümü, Fırat
Üniversitesi, Elazığ,
Türkiye,
ekacar@firat.edu.tr,
iserhatlioglu@firat.edu.tr

Özetçe—Bu çalışmada, elektrokardiyogram (EKG) işaretlerinin normal ve anormal olarak sınıflandırılması için Yapay Sinir Ağları (YSA), Destek Vektör Makineleri (DVM) ve k-En Yakın Komşu (k-EK) makine öğrenmesi yöntemlerinin bir uygulaması, sınıflandırma performansını ölçmek üzere gerçekleştirilmiştir. Bu kapsamda, açık-erişilebilir bir veri tabanından (PTBDB) EKG kayıtları elde edilmiştir. Veri tabanından elde edilen 80 normal ve 442 anormal EKG işaretinin, öncelikle morfolojik ve istatistiksel özellikleri çıkarılarak bir özellik seti oluşturulmuştur. Elde edilen özellik seti, YSA, DVM ve k-EK sınıflandırıcılara giriş olarak verilmiştir. Daha genel sonuçlar elde etmek üzere, 10-katlı çapraz doğrulama yöntemi kullanılmıştır. Gerçekleştirilen deneysel çalışma sonucunda, en iyi performansa DVM kullanılarak erişilmiştir ve %85,1 doğruluk, %89 duyarlılık, %51,7 özgüllük değerlerine ulaşılmıştır. DVM diğer sınıflandırıcılardan üstün olmuştur.

Anahtar Kelimeler — Biyomedikal İşaret İşleme; elektrokardiyogram; yapay sinir ağı; destek vektör makinesi; k-en yakın komşu algoritması; sınıflandırma

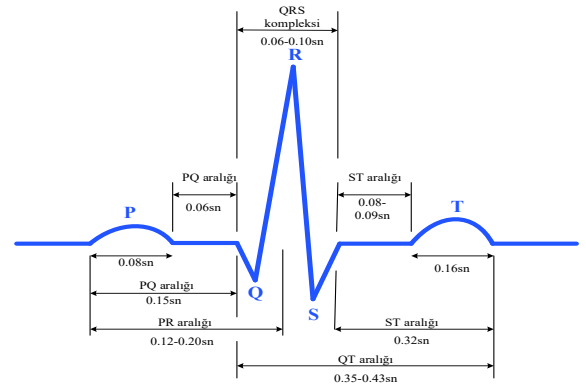
Abstract— In this study, an application of Artificial Neural Networks (ANN), Support Vector Machines (SVM), and k-Nearest Neighbor (k-NN) machine learning methods is performed to measure the classification performance of the models on classifying electrocardiogram (ECG) signals as normal and abnormal. In this scope, ECG records were obtained from an open-accessible database (PTBDB). A feature set was generated by extraction the morphological and statistical features of 80 normal and 442 abnormal ECG recordings obtained from the database, first. The feature set was applied as the input to ANN, SVM, and k-NN classifiers. The 10-fold cross-validation method was employed in the experiment in order to achieve more generalized results. As a result of the experimental study, the best classification performance was achieved using SVM, and 85.1% of accuracy, 89 of sensitivity and 51,7 specificity values were obtained. SVM was superior to other classifiers.

Keywords — Biomedical signal processing; electrocardiogram; artificial neural network; support vector machine; k-nearest neighbor algorithm; classification.

I. GİRİŞ

EKG olarak da bilinen bir elektrokardiyogram, kalbin elektriksel hareketliliğini temsil eden biyomedikal işaretlerdir. EKG işareti, P dalgası, QRS kompleksi ve T dalgası olan bazı kritik bölümlerinden ve dalga türlerinden oluşur [1–4]. EKG işareti, farklı frekanslar ve genlikler ile birbirinden ayrılan birkaç dalga içeren aynı zamanda kendini tekrarlayan bir durağan olmayan işarettir. Bu dalgalar; P dalgası, QRS kompleksi ve T dalgasıdır. P dalgası, atriyumdan ventriküle doğru kanın sıkıştırılması sırasında ortaya çıkan atriyal depolarizasyon sırasında oluşur. Q, R ve S dalgası bölümlerine ayrışabilen QRS kompleksi ise, sağ ventrikülden aorta doğru kan sıkıştığında ventriküler depolarize olduğunda ortaya çıkar. QRS kompleksi, 80 ms ile 120 ms arasında bir süreye sahiptir. Bununla birlikte, her QRS kompleksi bir Q dalgası, bir R dalgası ve bir S dalgası içermez; bir QRS kompleksinin birçok biçimsel formu bulunur. T dalgası, sonraki kalp atışına hazırlık olarak ventrikülerin repolarize zaman periyodunda üretilir [5,6].

EKG işareti kardiyologlara, kalbin ritim ve çalışması hakkında yararlı bilgiler sunmaktadır. EKG işaretinin analizi, farklı kalp hastalığı türlerinin belirlenmesi ve tedavi etmede



ŞEKİL I. NORMAL EKG İŞARETİNİN ŞEMATİK DİYAGRAMI

kullanılan etkili bir yoldur. Kardiyologlar, bir hastanın *EKG* işaretindeki belirli dalga formlarını tanı ve tanı için temel oluştururlar. Normal bir kalp atışına sahip *EKG* işaretinin tipik yapısı Şekil 1’de gösterilmiştir. *P, Q, R, S, T* dalgalarına ek olarak *EKG* işareti, standart *EKG* aralıkları olan *QT* aralığı, *ST* aralığı ve *PR* aralıklarını da içermektedir [7,8]. *EKG* kayıtları, işaretin özelliklerini görsel olarak kontrol eden ve işaretin en önemli parametrelerini tahmin eden bir uzman doktor tarafından incelenir ve bu işlemin sonucunda uzman doktor hastanın durumunu değerlendirir. Bu nedenle, *EKG* işaretlerinin tanınması ve analizi çok önemli bir role sahiptir [9,10].

EKG işaretini oluşturan spesifik kalp ritimlerinin saptanması, patolojik bulguların erken teşhisi ve kalp ritimlerinin tanı amaçlı sınıflandırılması kliniksel açıdan son derece önemli bir yer tutmaktadır [11]. Diğer biyomedikal işaretlerin pek çoğunda olduğu gibi, *EKG* işaretlerinin sınıflandırılmasında da, doğruluk ve duyarlılığı arttırmak üzere otomatik *EKG* işaret analizi ve aritmi bulguları için çeşitli yöntemler önerilmiştir. Bu metotlardan olan dalgacık paket entropisi (*DPE*) [12], ayrık dalgacık dönüşümü (*ADD*) [13], deneysel mod ayrışımı (*DMA*), temel bileşenler analizi (*TBA*) [8,14] gibi güçlü yöntemler yaygın bir şekilde kullanılmaktadır. Bu yöntemlere ilaveten, sınıflandırma performansını arttırmak, en ilgili özellikleri saptanmak ve hesaplama maliyetini düşürmek amacıyla çeşitli özellik seçme yöntemleri de sıklıkla kullanılmaktadır [15–17]. Son olarak, Bayes ağları, karar ağaçları [18], yapay sinir ağları (*YSA*) [1], *k*-en yakın komşu algoritması (*k-EK*), destek vektör makineleri (*DVM*) ve uç öğrenme makinesi (*UÖM*) [19,20] gibi sınıflandırıcılar literatürde kullanılmıştır.

Bu çalışmada, *EKG* işaretlerinin sınıflandırılması amacıyla, literatürde geçerliliği ve verimliliği ispatlanmış olan *YSA*, *DVM* ve *k-EK* makine öğrenmesi yöntemleri kullanılmış ve ilgili sınıflandırıcıların performansları karşılaştırılmıştır.

Bildirinin geri kalan bölümlerinde ise; ikinci bölümde, sınıflandırma için kullanılan veri seti, *YSA*, *DVM* ve *k-EK* sınıflandırıcıları hakkında detaylı bilgiler verilmiş, üçüncü bölümde bu sınıflandırıcılarla yapılan deneysel sonuçlar sunulmuş, dördüncü bölümde ise elde edilen sınıflandırma sonuçları tartışılmıştır.

II. MATERYAL VE METOD

A. PTBDB Veri Seti

Bu çalışmada, *Physikalisch-Technische Bundesanstalt Diagnostic ECG Database (PTBDB)* adlı veri tabanı kullanılmıştır. Veri tabanı, Almanya Berlin’de Benjamin Franklin Üniversitesinde bulunan Kardiyoloji Departmanı tarafından farklı kalp hastalıklarına sahip sağlıklı gönüllüler ve hastalar yardımıyla kaydedilmiştir. Veritabanındaki kayıtlar, çok çeşitli yaş ve teşhislerle 290 kişiden (her biri 1 ila 5 kayıtla temsil edilen) toplanmıştır.

Buna ek olarak, veri seti 549 kayıttan oluşmaktadır. Bu kayıtların her biri, eşzamanlı kaydedilen 15 işarete, geleneksel 12 derivasyon (*I, II, III, AVR, AVL, AVF, V1, V2, V3, V4, V5, V6*) ve 3 Frank derivasyonuna (*Vx, Vy, Vz*) sahiptir. Kayıtların tanı sınıflandırması ise; miyokard infarktüsü, kardiyomiyopati / kalp yetmezliği, dal bloğu, ritim bozukluğu, miyokardiyal ve

hipertrofi gibi sağlıklı ve çeşitli hastalık kategorilerini içermektedir [1,21,22]. Kullanılan veri tabanı, 54 sağlıklı gönüllüden alınan 80 normal kayıt ve 148 hastadan alınan 442 anormal kaydı içermektedir [22]. Böylece, 442 anormal ve 80 normal kayıt sırasıyla veritabanından seçilmiştir.

B. Yapay Sinir Ağları (YSA)

YSA, insan sinir sisteminin, çok katmanlı yapıdan oluşan sanal hesaplama modelidir. Genel bir *YSA* modelinde, sınıflayıcıyı besleyen bir girdi katmanı, incelenen veri alanındaki doğrusal olmama durumunu kavramak için kullanılan bir veya daha fazla gizli katman ve bir tahmin veya sınıf bilgisi için sayısal bir değer üreten çıktı katmanı bulunur. *YSA*, ağırlıkları ve biasları güncelleyen bir öğrenme süreci ile girdileri çıktılara eşlemeye çalışmaktadır. Bu çok katmanlı hesaplama yapısı aşağıdaki gibi (1)’deki modellenenir:

$$a_i = \varphi\left(\sum_{j=1}^N W_{ij}x_j + T_i^{gizli}\right) \quad (1)$$


Burada φ aktivasyon fonksiyonunu, N nöron sayısını, W_{ij} ağırlıkları, x_j *YSA* girişlerini ve son olarak T_i^{gizli} ise gizli katmandaki düğümler için eşik değerini temsil etmektedir [1,23,24].

C. K-En Yakın Komşuluk Sınıflandırıcısı

k-EK sınıflandırıcısı, tüm sınıflandırma algoritmalarından en basiti olarak bilinmektedir. Bu yöntem genellikle sınıflamaları yapmak için kullanılır. Sınıflandırma, giriş veya eğitim verilerini ve referans değerlerini ve veri setini içeren bir veri kümesi arasındaki minimum mesafeyi belirleyerek gerçekleştirilir. *k-EK* sınıflandırıcısı, *k-EK* ilkesini kullanan denetimli bir sınıflandırıcı türüdür. Bu sınıflandırma algoritmasında, test örnekleri için sınıf bilgileri, sınıf bilgisi olan eğitim örnekleri kullanılarak elde edilir. Bu yöntem, algoritma bir noktada birleşinceye kadar tekrarlanır. Sınıflandırmayı uygulamak için, Öklid uzaklığı olabilecek bir mesafe metriği kullanılır. *k-EK* yönteminin avantajı, verilerin sınıflandırılması için mesafe metriği ve k gibi yalnızca birkaç parametreye ihtiyaç duymasındır. *k-EK* tabanlı uygulamalarda, en yakın mesafeyi hesaplamak için k değerini ve mesafe metriğini seçebilmek önemli bir kriterlerdendir. *k-EK* tabanlı sınıflandırmada genellikle k tek değer seçilir [25].

D. Destek Vektör Makineleri Sınıflandırıcısı

DVM, Vapnik tarafından önerilmiştir. Literatürde sık kullanılan etkin ve basit yöntemlerin başında gelen *DVM*’ler çoğunlukla ikili sınıflandırma yapılması durumunda kullanılmaktadırlar. Şekil 2’de görüldüğü gibi *DVM*



ŞEKİL II. (A) TOLERANSIN BELİRLENMESİ, (B) GRUPLARIN DÜZLEMDE GÖSTERİLMESİ

sınıflandırıcısı, h-düzlemi kullanarak d-boyutlu verilerin tam iki sınıfa ayrılmasını sağlayan bir sınıflandırıcıdır [26]. H düzleme en yakın pozitif ve negatif örnekler arasındaki mesafeye ayırıcı h- düzleminin toleransı olarak isimlendirirsek, *DVM* yöntemi bu toleransın en yüksek olduğu bir h- düzlemi bulabilmesi amaçlanmaktadır. *DVM*, denetimli bir sınıflandırma metodudur ve hedef seti olarak da bilinen bir eğitim seti gerektirir. Eğitim veri setinde, bir özellik vektörü ve ona ait bir sınıf değeri bulunmaktadır. Eğitim verilerine dayanan öğrenme algoritması, bilinmeyen girdi verilerini sınıflandırmak için bir karar fonksiyonu çıkarmaktadır. H- düzlemi, en yakın veri noktasının geometrik mesafesini maksimum düzeye çıkarır [25].

III. DENEYSEL SONUÇLAR

Deneysel sonuçlar, 80 normal ve 442 anormal işaret üzerinde yapılan simülasyondan sonra *PTB* Diagnostik *EKG* veritabanı (*PTBDB*) veritabanının II. derivasyon kanalı kullanılarak elde edilmiştir. Deneysel çalışma, *MATLAB*® (2016a) yazılımı kullanılarak gerçekleştirilmiştir. Kullanılan bütün *EKG* işaretleri Tablo I'de açıklandığı gibi 11 tanışal özellik ile temsil edilmiştir.

Bu özellikler kullanılarak, toplam 522 *EKG* işaretinden hedef matrisi ile birlikte sınıflandırıcıların girişine verilmek üzere 522x12 boyutunda bir özellik vektörü oluşturulmuştur. Bir sınıflandırıcının performansını ölçmek için, k-katlama çapraz doğrulama, karmaşıklık matrisi, alıcı işletim karakteristik (Receiver Operating Characteristic-ROC) eğrisi, temel değerlendirme araçlarıdır.

Bu çalışmada sınıflandırma amacıyla, 10-katlı çapraz doğrulama bölme tekniği kullanılmıştır. Model doğrulama yöntemini kullanarak, istatistiksel analiz sonuçlarının bağımsız veri kümesi olarak basitleştirilebileceğini öngören yöntem çapraz doğrulama denilmektedir. Çapraz doğrulama, orijinal *EKG* örneklerini sırasıyla eğitim ve test alt örneklerine ayırarak, test analizinin gerçekleştirilmesini içermektedir. Çapraz doğrulama yöntemi sınıflandırıcının değişkenliğini azaltmak için, eğitim ve test alt örneklerinin farklı bölümlerini kullanarak birçok döngüde gerçekleştirilir. Döngüler tamamlandıktan sonra doğrulama sonuçlarının ortalaması alınır [25]. Ayrıca sınıflandırma sonuçlarından elde edilen karmaşıklık matrisi yardımıyla Duyarlılık (*DUY*), Özgüllük (*ÖZG*) ve Doğruluk (*DOĞ*) metrikleri elde edilir. Alıcı işletim karakteristik (*AİK*) eğrileri ve bu eğrilerin altında kalan alanlar da dikkate alınmıştır. Buna göre bu metrikler aşağıda verilmiştir.

$$DOĞ = \frac{(GP + GN)}{(GP + GN + YP + YN)} \quad (2)$$

$$DUY = \frac{GP}{(GP + YN)} \quad (3)$$

$$ÖZG = \frac{GN}{(GN + YP)} \quad (4)$$

Yukarıdaki denklemlerde, anormal *EKG* kayıtlarının sınıflandırıcılar tarafından doğru ve yanlış tahmin edilme sayıları sırasıyla Gerçek Pozitif (GP) ve Yanlış Pozitif (YP);


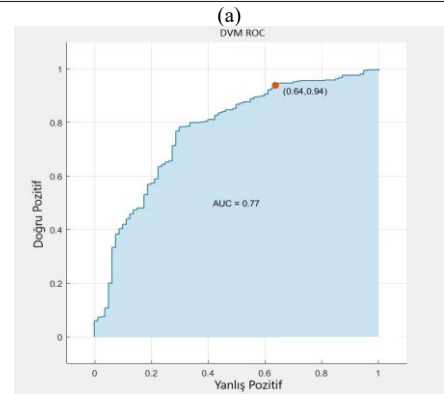
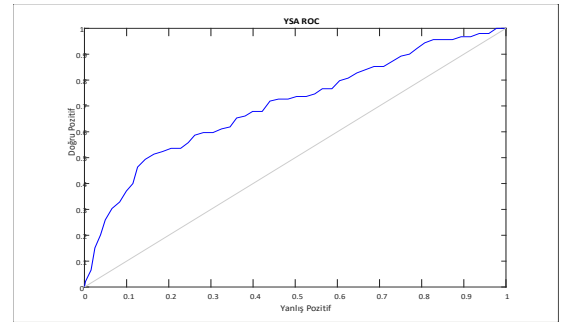
normal *EKG* kayıtlarının doğru ve yanlış tahmin edilme sayıları sırasıyla Gerçek Negatif (GN) ve Yanlış Negatif (YN) ile temsil edilmiştir. Bu bilgilerin elde edilmesinden sonra *EKG* işaretlerinin *YSA* (Kullanılan gizli katman sayısı 2 ve sırasıyla her bir katmanda 15,10 nöron, eğitim ise trainlm, Levenberg-Marquardt optimizasyonuna göre ağırlık ve yanlılık değerlerini güncelleyen bir ağ eğitim fonksiyonu ile yapılmış olup eğitim ve test 52 iterasyonda son bulmuştur.) *DVM* (Kernel fonksiyonu Kuadratik, kısıtlama düzeyi 1) ve *k-EK* (komşu sayısı 100, uzaklık olarak kullanılan metrik Öklid uzaklığı) sınıflandırıcılarına verilerek elde edilen performansları Tablo

TABLO I. MORFOLOJİK VE İSTATİSTİKSEL ÖZELLİKLER

Morfolojik Özellikler	İstatistiksel Özellikler
QRS kompleksi genliği (mV)	Maksimum
PR aralığı (ms)	Minimum
ST aralığı (ms)	Ortalama
QT aralığı (ms)	Varyans
P dalgası genliği (mV)	Basıklık ve Çarpıklık

TABLO II. SINIFLANDIRMA SONUÇLARI

Sınıflandırıcı	DOĞ (%)	DUY (%)	ÖZG (%)
YSA	81.7	89.4	40.6
SVM	85.1	89.0	51.7
K-EK	84.3	85.8	45.0



ŞEKİL III. (A) YSA ROC EĞRİSİ, (B) DVM ROC EĞRİSİ, (C) K-EK AİK EĞRİSİ

2’de verilmiştir. Aynı zamanda sınıflandırma işleminin sonucunda alıcı işletim karakteristik eğrileri, Şekil 3’de gösterilmiştir.

IV. TARTIŞMA

Bu çalışmada, *Physikalisch-Technische Bundesanstalt Diagnostic ECG Database (PTBDB)* adlı veri tabanından elde edilen *EKG* kayıtları, literatürde geçerliliği olan popüler makine öğrenme yöntemlerden olan *YSA*, *DVM* ve *k-NN* ile sınıflandırılmıştır. Bu sınıflandırıcıların, *DUY*, *ÖZG* ve *DOĞ* gibi performans metrik değerleri elde edilmiştir. Sınıflandırma sonuçları, *DVM* kullanılarak % 85,1 doğruluk, % 89,0 duyarlılık, % 51,7 özgüllük, *YSA* ile % 81,7 doğruluk, % 89,4 duyarlılık, % 40,6 özgüllük ve *k-NN* % 84,3 doğruluk, %85,8 duyarlılık, % 45 özgüllük değerleri ile doğrulanmıştır. Performans metriklerinin daha da iyileştirilmesi adına, morfolojik ve istatistiksel özelliklerin yanı sıra zaman-frekans veya doğrusal olmayan özellikler de eklenebilir.

Gelecekte yapılacak çalışmalarda, farklı makine öğrenmesi metodları ve optimizasyon teknikleri kullanılarak *EKG* işaretlerinin sınıflandırılmasına yönelik çalışmalar yapılması amaçlanmaktadır.

KAYNAKLAR

- [1] A. Diker, Z. Cömert, E. Avcı, A Diagnostic Model for Identification of Myocardial Infarction from Electrocardiography Signals, *Bitlis Eren Univ. J. Sci. Technol.* 7 (2017) 132–139.
- [2] M.M. Al Rahhal, Y. Bazi, H. Alhichri, N. Alajlan, F. Melgani, R.R. Yager, Deep learning approach for active classification of electrocardiogram signals, *Inf. Sci. (Ny)*. 345 (2016) 340–354. doi:10.1016/j.ins.2016.01.082.
- [3] E. Ramanujam, S. Padmavathi, Double constrained genetic algorithm for ECG signal classification, 1st Int. Conf. Emerg. Trends Eng. Technol. Sci. ICETETS 2016 - Proc. (2016). doi:10.1109/ICETETS.2016.7603010.
- [4] S. Chen, W. Hua, Z. Li, J. Li, X. Gao, Heartbeat classification using projected and dynamic features of ECG signal, *Biomed. Signal Process. Control.* 31 (2017) 165–173. doi:10.1016/j.bspc.2016.07.010.
- [5] Chung-Ching Peng A, A Memory-Optimize Architecture for ECG Signal Processing, 2011.
- [6] M. Rahman, M. Nasor, An algorithm for detection of arrhythmia, in: 2011 1st Middle East Conf. Biomed. Eng. MECBME 2011, 2011: pp. 243–246. doi:10.1109/MECBME.2011.5752111.
- [7] H.D. Hesar, M. Mohebbi, A Multi Rate Marginalized Particle Extended Kalman Filter for P and T Wave Segmentation in ECG Signals, *Biomed. Heal. Informatics*. 2194 (2018) 1–12. doi:10.1109/JBHI.2018.2794362.
- [8] Z. Cömert, A.Fatih Kocamaz, Determination of QT interval on synthetic electrocardiogram, in: *Signal Process. Commun. Appl. Conf. (SIU)*, 2015 23th, 2015: pp. 1–4.
- [9] S. Conforto, A. Laudani, F. Oliva, F.R. Fulginei, M. Schmid, Classification of ECG patterns for diagnostic purposes by means of neural networks and support vector machines, 2013 36th Int. Conf. Telecommun. Signal Process. TSP 2013. (2013) 591–595. doi:10.1109/TSP.2013.6614003.
- [10] A. Gautam, M. Kaur, ECG Analysis using Continuous Wavelet Transform (CWT), 2 (2012) 632–635.
- [11] S. Karpagachelvi, Classification of ECG Signals Using Extreme Learning Machine, *Comput. Inf. Sci.* 4 (2011) 42–52.
- [12] T. Li, M. Zhou, ECG classification using wavelet packet entropy and random forests, *Entropy*. 18 (2016) 1–16. doi:10.3390/e18080285.
- [13] Z. Cömert, A.F. Kocamaz, Using wavelet transform for cardiocography signals classification, in: 25th Signal Process. Commun. Appl. Conf., 2017: pp. 1–4. doi:10.1109/SIU.2017.7960152.
- [14] J. Kim, H. Shin, Y. Lee, M. Lee, Algorithm for classifying arrhythmia using Extreme Learning Machine and principal component analysis., *Conf. Proc. IEEE Eng. Med. Biol. Soc.* 2007 (2007) 3257–3260. doi:10.1109/IEMBS.2007.4353024.
- [15] S. Velappan, D. Murugan, Opposition-based Firefly Algorithm Optimized Feature Subset Selection Approach for Fetal Risk Anticipation, *Mach. Learn. Appl. An Int. Journal,(MLAIJ) Vol. 3* (n.d.) 55–64.
- [16] S. Velappan, D. Murugan, M. Boopathi, A Hybrid Filter-Wrapper Attribute Reduction Approach For Fetal Risk Anticipation, *Asian J. Res. Soc. Sci. Humanit.* 7 (2017) 1094–1106.
- [17] S. Velappan, D. Murugan, S. Prabha, M. Boopathi, Genetic Algorithm based feature subset selection for fetal state classification, *J. Commun. Technol. Electron. Comput. Sci.* 2 (2015) 13–17.
- [18] Y. Kaya, H. Pehlivan, KNN, NN, Bayes, DT ve SVM Kullanılarak EKG Vurularının Sınıflandırılması, 2ND Int. Symp. Innov. Technol. Eng. Sci. (2014) 1–10.
- [19] S. Karpagachelvi, Classification of Electrocardiogram Signals With Extreme Learning Machine and Relevance Vector Machine, *J. Comput. Sci.* 8 (2011).
- [20] Z. Cömert, A.F. Kocamaz, S. Gungor, Cardiotocography signals with artificial neural network and extreme learning machine, in: 24th Signal Process. Commun. Appl. Conf., 2016. doi:10.1109/siu.2016.7496034.
- [21] H. Beyramienanlou, N. Lotfivand, Shannon’s Energy Based Algorithm in ECG Signal Processing, *Comput. Math. Methods Med.* 2017 (2017) 16. doi:10.1155/2017/8081361.
- [22] H. Yang, S.T. S Bukkapatnam, R. Komanduri, Spatiotemporal representation of cardiac vectorcardiogram (VCG) signals, *Biomed. Eng. Online*. (2012). doi:10.1186/1475-925X-11-16.
- [23] S.P. Kulkarni, DWT and ANN Based Heart Arrhythmia Disease Diagnosis from MIT-BIH ECG Signal Data, *Int. J. Recent Innov. Trends Comput. Commun.* 3 (2015) 276–279.
- [24] Z. Cömert, A.F. Kocamaz, Comparison of Machine Learning Techniques for Fetal Heart Rate Classification, *Acta Phys. Pol. A*. 132 (2017) 451–454. doi:10.12693/APhysPolA.131.451.
- [25] Swasthik, U. Desai, Automated Detection of Cardiac Health Condition using Linear Techniques, in: *IEEE Int. Conf. Recent Trends Electron. Inf. Commun. Technol.*, 2017.
- [26] S. Velappan, D. Murugan, Fetal State Determination using Support Vector Machine and Firefly Optimization, *Int. J. Knowl. Based Comput. Syst.* 2 (2014) 7–12.